

[卒業研究 中間発表]

表現学習による ファイル断片の 形式識別モデルの研究

ゴーチェ研究室

5i 10 片野 凱介



公開厳禁

[目 次]

01 研究の概要

02 研究内容と進捗

03 結果の考察・展望

01

研究の概要

フォレンジックス / 背景と目的 / 関連研究

[フォレンジックス]

コンピュータ・フォレンジックス

コンピュータ上で発生した、セキュリティインシデントの証拠を残すための一連の作業の総称 *1 (技術)

例) 破損ファイルの復旧、ステガノグラフィの解析

補足: 狭義には法的な証拠



[課題と目的]

一時対応の時点から、高度な技術を持った管理者が対応に当てる必要がある *1
→ 優先順位付けの判断が属人的

→ 手作業・特徴量抽出ツール: 高コスト・効率低下

手法: 自動的な特徴抽出(表現学習)
成果物: 形式識別モデル
目的: 復旧対象の探索を効率化する
目標: NLPモデルの有効性(CNN比較)

[関連研究]

Magika: AI-Powered Content-Type Detection

軽量、多数の形式。

モデルの重み: 1MB、推論時間: 10ミリ秒以下
結合入力 + ネット構造による特徴抽出
対応のファイル種類: 113種類以上

**圧倒的サンプル数、
識別に有利な断片化。**

2,400万の訓練データ、120万のサンプル
先頭・中間・末尾から各512バイトの断片化
フッタ・マジックナンバー含むヘッダ→有利

[関連研究]

FiFTy: Large-Scale File Fragment Type Identification Using Convolutional Neural Networks

圧倒的な再現性。

OSS実装 & 学習済みモデル公開
バイト列→埋め込み→1D-CNN→全結合
コーパスの公開: FFT - 75 Dataset *4

**マジックナンバーに、
依存しない断片化。**

断片長: 512バイト(または 4096バイト)
抽出方法: 重複を認めるランダムな位置
全7,680,000サンプル(学習用80%)

02


研究内容と進捗

先行事例と手法 / 実験設定 / 実験結果

[先行事例と手法]

事例	Sceadan *3 (スキードン)	Co-Occurrence matrix CNN *4	FiFTy *4
方式	手設計特徴量と SVM分類器	共起頻度行列を 画像化、CNNに入力	1次元畳み込みニューラルネットワーク
512B の精度	54.7 %	56.8 %	62.6 %

[先行事例と手法]



データ構造: 順序的 $\wedge$ 長距離

仮説: 自然言語処理

モデル: LSTM/GRU

特徴: 長距離の依存関係保持



ファイル断片の識別評価


先行研究と同一データセット

精度 (Top-1 Accuracy) 主軸

[実験設定]

- モデル種類: CNN / LSTM / GRU
- 比較の公平性:
 - バッチ: 128
 - エポック: 30
 - サブセット比率: 12%
 - パラメータ規模: 約29万($\pm 5\%$) ほか
- 乱数: NumPy・PyTorchで固定
- 早期終了: 許容上限回数: 6 (監視指標: val_loss)

[実験結果]



- Loss: Train/Val とも単調減 過学習なし
- Acc: ~0.64で頭打ち
- Top-3: ~0.73で早期に安定

精度が高い順
GRU
LSTM
CNN

[実験結果]

手法	FiFTy	FiFTyの再現	自然言語処理	軽量化
学習モデル	1D-CNN	1D-CNN	LSTM	<u>GRU</u>
512BのTop1精度 (学習データの量)	62.6 %	61.9 % (10%)	64.1% (10%)	<u>65.3 %</u> <u>(10%)</u>

03

結果の考察・展望

結果の考察 / 今後の展望 / 参考文献

[結果の考察]

なぜ CNN より GRU/LSTM が良かったのか

データ構造
(順序的 ∧ 長距離)
+
長距離の依存関係保持
→ 相性が良い

- CNN: 空間的な局所パターン抽出
→ 遠距離パターンの同時統合🤔
- LSTM/... 回帰結合による記憶
→ 時系列データの集約👍

[結果の考察]

なぜ LSTM より GRU が僅かに良かったのか

データ(サンプル)が少なかった
→100%で学習は計算資源不足


GRU: LSTMを簡易的にしたモデル

→構造がシンプル

→学習が早くまとまりやすい

→パラメータの影響を受けづらい

[実験結果(フル)]



精度が高い順
GRU
LSTM
CNN

[実験結果(フル)]

学習モデル	1D-CNN	1D-CNN	LSTM	GRU
512B (10%)	-	61.9 %	64.1%	65.3 %
512BのTop1 精度(100%)	62.6 %	66.9 %	70.0 %	70.2 %

[今後の展望]

自己注意機構の採用

- ✓ 自然言語処理などで主流
(Transformer/Perceiver)
- ✓ 局所・非局所の両相関を捕捉
→ 断片は長距離文脈が途切れ
やすい点に作用

2D-CNNとの併用

- ✓ バイト列を2Dグレースケール
画像化(0~255の濃淡)
ビット境界を跨ぐ分割の対策
- ✓ 2D分岐: intrabyteを捉える
(1バイト内ビット構造)
- 💡 1D分岐: interbyte を捉える
(バイト間の並びパターン)

[ま と め]

GRUで70.2%の精度



達成した目標:

CNNと比較した、NLPモデルの有効性の検証



次の目標:


Transformer(高精度な短離散系列の分類)

77.5% ↑ (FiFTy4096Bシナリオ#1)

[参考文献]

- *1 S. 郡司, T. 谷川, and K. 支倉, “バーチャルマシンで実現するコンピュータ・フォレンジックス (Solution of Computer Forensics with Virtual Machines),” NEC技報, Vol. 58, No. 2, pp. 43-46, 2005.
- *2 [1] G. Mittal, P. Korus, and N. Memon, “File Fragment Type (FFT-75) Dataset,” IEEE DataPort, 2021. [Online]. Available: <https://iee-dataport.org/open-access/file-fragment-type-fft-75-dataset>. [Accessed: 17-Oct-2025].
- *3 N. Beebe and S. Garfinkel, “SCEADAN: Systematic Classification Engine for Advanced Data ANalysis,” presented at OSDFCon 2014, 2014.
- *4 G. Mittal, P. Korus, and N. Memon, “FiFTy: Large-scale File Fragment Type Identification using Neural Networks,” arXiv, arXiv:1908.06148, 2020

付録：CNNの構成




入力: 512バイト列


カーネルサイズ: 27
埋め込み次元数: 64
畳み込み出力チャンネル数:
128

全結合中間層ユニット
(hidden_dim): 256


付録：100%の損失率



付録：100%のLR



付録：100%のTop-3



[付録: Val Top-1 の差]

記録した中で最大: 0.162%

同一条件(CNN, 12%ほか)で、

Val Top-1 Acc:

- 0.628307292

- 0.629322917

絶対差: 0.001015625

小さい値に対する相対差: 0.161644630%

〔 付 録 : C N N 〕

得意: 空間構造をもつデータ(画像・音声など)の特徴を抽出する

畳み込み層(Convolution layer)

→ 画像の局所パターンを検出(縁・角・色の変化など)

プーリング層(Pooling layer)

→ 位置という外乱に対する頑健性

全結合層(Fully Connected)

→ 抽出した特徴をもとに最終的な分類などを行う

〔 付 録 : L S T M 〕

得意: 時間的(系列的)な依存関係を持つデータに強い

忘却ゲート (Forget gate): どの過去情報を捨てるか

入力ゲート (Input gate): どの新情報を覚えるか

出力ゲート (Output gate): 次の出力に何を渡すか

→ これらを「メモリセル」を通じて情報を長期間保持

〔 付 録 : G R U 〕

特徴: LSTM とほぼ同じだが、構造を簡略化して高速化

更新ゲート (Update gate):

過去情報をどれだけ残すか

リセットゲート (Reset gate):

新しい情報をどれだけ取り入れるか

〔 付 録 : 目 的 変 数 と 評 価 指 標 〕

目的変数:

0～74 の 75 通りのクラスID(ファイルの種類、拡張子)

モデルはこのIDを予測する他クラス分類タスクとして訓練

データはファイル分割のみでバイトをそのまま数値で扱い

[付 録 : 各 種 環 境]

- OS: Ubuntu 24.04.2 LTS (tailscaleによるSSH)
- GPU: NVIDIA GeForce RTX 2080
- CUDA Version: 12.2
- Python: 3.12.3
 - numpy: 2.3.3
 - torch: 2.5.1

付 録： 質 疑

Q. 表現学習とは

- 機械学習のタスクの実行に関して、データの特徴や構造を自動的に学び取り、抽出する学習手法
- CNN では Embedding 層(埋め込み層)で、離散的な入力を連続値の表現ベクトル(低次元)に変換
 - 距離が近いデータを近いベクトル位置に配置する

付 録： 質 疑

Q. バッチ、エポック、パラメータ規模、val_loss

- バッチ: 学習データを少しずつ分けて処理する単位
- エポック: 全データを1回すべて使って学習する単位(何周するか)
- パラメータ規模: モデル内部の重み w とバイアス b の総数
 - 1つのニューロンの計算: $y = f(w * x + b)$
 - 重み: 重要度、バイアス: 調整項、 x : 入力ベクトル
- val_loss: 訓練に使っていない検証データ(validation data)で計算した誤差(loss)の値