

系列モデルを用いた大規模ファイル断片の種別識別

片野 凱介[†]

[†] 有明工業高等専門学校 創造工学科 情報システムコース
Gauthier Lovic 研究室

1 背景と目的

ファイル断片の種別識別は、破損・断片化したデータを扱うデータカービングやメモリフォレンジクスにおいて重要である。先行研究 FiFTy [1] はデータセット FFT-75 の 512B 断片に対し、局所受容野に基づく特徴抽出を主とする CNN を適用し高精度を示したが、バイト列を順序ある系列として扱う系列モデル (GRU / LSTM / Transformer) の有効性比較は十分でない。そこで本研究では、同データセットにおいて、CNN と系列モデル 3 種を同一条件で比較し、**系列モデルの相対的な有効性と誤分類傾向について評価・検討**することを目的とした。

2 手法

2.1 問題設定とデータセット

クラス集合は全 75 種類のファイル種別 (ファイル形式) であり、 $\mathcal{Y} = \{0, 1, \dots, 74\}$ と定義した。モデルは入力 x から予測ラベル $\hat{y} \in \mathcal{Y}$ を出力した。ここで x は長さ 512 のバイト列であり、 t 番目のバイト値を b_t とおくと、次式で表される。

$$x = (b_1, b_2, \dots, b_{512}), \quad b_t \in \{0, 1, \dots, 255\}, \quad (1 \leq t \leq 512)$$

具体的なデータセットとして、FiFTy [1] と同じ FFT-75 から 512B, scenario #1 を採用したため、規模は学習 (Train) データ 6,144,000 件、検証 (Val) データ 768,000 件、テスト (Test) データ 768,000 件であった。なお、前述の想定する背景を再現し、断片は各ファイルのランダムな位置から 512B を切り出した (ヘッダを含む断片と含まない断片が混在)。

2.2 入力表現とモデル

本研究では、バイト値を離散トークンとみなし、語彙サイズを $V = 256$ 、埋め込み次元を d とすると、Embedding 行列 $E \in \mathbb{R}^{V \times d}$ により、各時刻 t の入力は $z_t = E[x_t] \in \mathbb{R}^d$ として表現した。入力長は固定長 512 を採用したため、padding や mask は用いなかった。この入力表現の他に、データセット、損失関数、ハイパーパラメータ、早期終了、評価指標、およびモデル規模 (パラメータ数を概ね同程度に調整) を可能な範囲で統一し比較した。

モデルは、FiFTy [1] を再現した 1D-CNN と、系列モデルの GRU、双方向 LSTM, Transformer を用いた。

3 結果

最良エポック時におけるテストデータに対する指標を表 1 に示した。また、正答率の学習曲線を図 1 に示した。

本実験 (48 epoch 設定) では、Top-1/Top-3/Macro-F1 のいずれの指標においても系列モデルが CNN を上回る傾向を示し、特に **GRU が最も性能が高く**、テストデータに対して Top-1 accuracy 70.1% を達成した。これは比較基準である CNN (66.9%) に対して +3.2pt, LSTM (67.9%) に対して +2.2pt, Transformer (68.1%) に対して +2.0pt の改善となった。

表 1: テストデータに対する各モデルの性能指標

Model	Top-1	Top-3	Loss	Macro-F1
CNN	0.6690	0.7510	1.1773	0.666
GRU	0.7010	0.7790	1.0520	0.703
LSTM	0.6790	0.7610	1.1310	0.678
Transformer	0.6810	0.7600	1.1634	0.678




図 1: 各モデルの学習曲線 (Top-1 accuracy, Train/Val)

4 考察

系列モデルが CNN を上回った結果は、断片がランダム位置から切り出されヘッダ情報の有無が混在するため、局所的な特徴だけでは判別困難な場合が生じるという設定と整合する。すなわち、**系列モデルは断片全体に散在する特徴を統合でき、局所特徴抽出を主とする CNN より有利に働いた可能性が高い**。また、系列モデル間では、GRU は LSTM より簡潔なゲート構造を持ち、同程度の表現力を比較的安定に学習できるため、512B 条件に適合したと考えられる。一方、Transformer は位置表現と最適化条件 (正則化, 学習率スケジュール, モデル規模など) の設計に敏感であり、モデル間の公平比較のためにそれらを共通化した本設定では最適化が不十分であった可能性がある。したがって、より高精度を与える設定が存在し得る。

誤分類傾向は、混同行列の上位誤分類を見ると 7z / xz / bz2 など圧縮形式への誤分類が各モデルで目立った。これは、断片がファイル固有構造を含まずランダム値に近い場合、モデルの出力が圧縮データに近い統計的性質へ収束した結果と解釈できる。なぜなら、圧縮形式はエントロピー符号化等を用いることが多く、出力バイト列が 0-255 の値を比較的均等に取りやすいためである。また Macro-F1 からは、xz / exe のような高エントロピー形式で極端に低い値が見られ、短断片条件における識別上限 (情報制約に起因する難しさ) が示唆された。一方で jpeg など画像系は比較的高水準であり、先行研究で指摘されているコンテナ形式と内部データ (画像等) の混同は起こり得るものの、本条件ではまず高エントロピー系の相互誤分類がボトルネックになりやすい。

5 結論

FFT-75 512B, scenario #1 における CNN に対する系列モデルの有効性比較および誤分類傾向の評価・検討を行い、系列モデル、とりわけ GRU が CNN に対する有力な代替となることを示し、同時に高エントロピー形式に起因する構造的な難所と運用上の対策方針を明確化できた。ただし、実運用 (ファイルカービング前処理) では、誤分類が復元探索空間の誤拡大と誤検出増加につながるため、Top-k の併用や複数断片の統合が現実的な対策となる。また、本研究は 512B, scenario #1 に限定され、断片長 (4096B など) やシナリオ変更で結論が変化し得るほか、高精度を期待する場合は Transformer の最適化検討に余地がある。

参考文献

- [1] G. Mittal, P. Korus, と N. Memon, 「FiFTy: Large-scale File Fragment Type Identification using Neural Networks」. [Online]. 入手先: <https://arxiv.org/abs/1908.06148>