

系列モデルを用いた 大規模ファイル断片の種別識別

片野 凱介

有明工業高等専門学校 創造工学科 情報システムコース

Gauthier Lovic 研究室

本研究では、ファイル断片（512 B）からファイル種別（拡張子）を識別する問題に対し、自然言語処理で用いられる系列モデル（GRU/LSTM/Transformer）を適用し、その有効性（先行研究との精度比較）と誤分類傾向について評価・検討した。

1. 研究背景と課題..... 2	5. 実験結果と考察（精度） . . 6
背景..... 2	6. 実験結果と考察（誤分類傾
従来手法と課題..... 2	向） 7
2. 問題設定とデータセット	Macro-F1 7
FFT-75 3	混同行列..... 8
3. 先行研究と提案手法..... 4	7. まとめ..... 9
先行研究 FiFTy 4	Top-1 accuracy 12
提案する系列モデル..... 4	Top-3 accuracy 13
4. 手法と設計..... 5	交差エントロピー誤差..... 14
同一の Embedding 層（ $d =$	交差エントロピー誤差..... 15
64） 5	Macro-F1 16

1. 研究背景と課題

背景

断片化した破損ファイルの復元

- データカービング
- メモリフォレンジクス

断片のファイル種別を知りたい


従来手法と課題

- ヘッダーのマジックナンバー
 - 断片化によって破損
- 手設計特徴量を用いた分類
 - 設計に依存した汎用度

0x00	FF D8	JPEG のマジックナンバー (Start Of Image)
0x02	FF E0	APP0 セグメント (JFIF) マーカー
0x04	00 10	セグメント長が自身を含む 16 バイト
0x06	4A 46 49 46 00	識別子 (ASCII なので JFIF\0)
0x0B	01 01	バージョン
0x0D	01	密度単位
⋮	⋮	⋮

2. 問題設定とデータセット FFT-75

- クラス数: 全 75 ファイル
- 入力: 512 B をランダム抽出
 - 各バイトは 0-255 の整数値
- 出力: ファイル種別ラベル
- 学習データ 6,144,000 件
- 検証データ 768,000 件
- テストデータ 768,000 件
- 512B, scenario #1



3. 先行研究と提案手法


先行研究 FiFTy

- 1D-CNN
- 局所的な特徴抽出に強い
- 離れた位置にある文脈の統合に向かない



提案する系列モデル

- LSTM/GRU/Transformer
- バイト列をトークン列（言語）として扱い，順序依存関係を学習
- 自然言語処理で用いられる



4. 手法と設計

モデル	特徴	パラメータ数
CNN	局所パターン	289,995
GRU	長期依存	291,211
LSTM	LSTM を単純化したゲート構造	288,535
Transformer	自己注意	302,283

同一の Embedding 層 ($d = 64$)

- 系列長 $T = 512$
- 入力（1 サンプル）: $x = (x_1, \dots, x_T)$, $x_t \in \{0, 1, \dots, 255\}$
- ラベル集合: $y = \{1, 2, \dots, 75\}$, $y \in \mathcal{Y}$
- 分類器: $f_\theta : \{0, \dots, 255\}^T \rightarrow \mathbb{R}^{75}$, $z = f_\theta(x)$

5. 実験結果と考察（精度）

- 系列モデルは，いずれも CNN と同等以上の精度を示した
→ 系列モデルは，断片全体に離散する特徴を統合できる
- Top-1 accuracy は GRU が 70.1% で最も高精度だった
→ 今回のデータセットや共通化した条件が GRU に適していた

Model	Top-1 Accuracy	Top-3 Accuracy	Loss	Macro-F1
CNN（基準）	66.9%	75.1%	1.1773	0.666
GRU	70.1%	77.9%	1.0520	0.703
LSTM	67.9%	76.1%	1.1310	0.678
Transformer	68.1%	76.0%	1.1634	0.678

6. 実験結果と考察（誤分類傾向）


ラベル	Macro-F1 CNN	Macro-F1 GRU	GRU - CNN
7z	0.070600	0.079064	0.008464
xz	0.059206	0.059463	0.000257
bz	0.114836	0.157184	0.042348
zip	0.167506	0.286452	0.118946
exe	0.066692	0.056708	- 0.009984
jpg	0.808753	0.893484	0.084731
pdf	0.351193	0.414917	0.063724
txt	0.955805	0.968193	0.012388

Macro-F1

高エントロピー形式（xz/ exe）で値が低い

→ 断片がランダムに近いとき，比較的均等なバイト値を持つ圧縮形式に誤分類

6. 実験結果と考察（誤分類傾向）



混同行列

圧縮形式への誤分類がモデルを問わず目立った

→ 断片がランダムに近いとき、比較的均等なバイト値を持つ圧縮形式に誤分類

7. まとめ

- 条件を可能な限り統一し，先行研究の CNN と系列モデル（LSTM／GRU／Transformer）を比較した
 - ▶ 結果，系列モデルは CNN ベースラインより高性能であり，特に GRU が本条件下で最良の精度を示した
- 512B 単一断片分類では圧縮・暗号・実行形式など高エントロピー系が難所となり，誤分類が圧縮形式へ集まりやすい，という傾向が観測された
- 一方で，本研究の統一条件下における比較結果であり，条件次第では大きく結果が変わる可能性がある
 - ▶ 断片長の長さ
 - ▶ Transformer の最適化

テスト集合 $\mathcal{D}_{\text{test}}$ は N 個のサンプルからなる列として次で定義される。

$$\mathcal{D}_{\text{test}} = \{(x_n, y_n)\}_{n=1}^N, \quad x_n \in \{0, 1, \dots, 255\}^T, \quad y_n \in \mathcal{Y}$$

- バッチサイズ（実装上のミニバッチ処理に用いる）： B
- 系列長： $T = 512$
- クラス集合（全 75 クラス）： $\mathcal{Y} = \{0, 1, \dots, 74\}$
- 1 バイトの値の集合： $\{0, 1, \dots, 255\}$
- n 番目サンプルの入力（長さ T のバイト列）： x_n
- それに対する正解ラベル（真のラベル; クラス ID）： y_n
- テストサンプル総数： N

評価手法

また，モデル出力（ロジット）を

$$z^{(n)} = \left(z_0^{(n)}, z_1^{(n)}, \dots, z_{74}^{(n)} \right) \in \mathbb{R}^{75}$$

とし，予測ラベル（Top-1）は次で与える．

$$\hat{y}_n = \arg \max_{k \in \mathcal{Y}} z_k$$

評価手法

Top-1 accuracy

指示関数 $\mathbf{1}[\cdot]$ (真なら 1, 偽なら 0) を用いて次と定義する.

$$\text{acc-1} = \frac{1}{N} \sum_{n=1}^N \mathbf{1}[\hat{y}_n = y_n]$$

評価手法

Top-3 accuracy

サンプル n のロジット $z^{(n)}$ について、値の大きい順に上位 3 つのクラス集合を次と定義する.

$$\text{Top3} \left(z^{(n)} \right) \subset \mathcal{Y}$$

このとき次が成り立つ.

$$\text{acc-3} = \frac{1}{N} \sum_{n=1}^N \mathbf{1} \left[y_n \in \text{Top3} \left(z^{(n)} \right) \right]$$

評価手法

交差エントロピー誤差

まず softmax 確率を次と定義する．

$$p_k^{(n)} = \frac{\exp\left(z_k^{(n)}\right)}{\sum_{j \in \mathcal{Y}} \exp\left(z_j^{(n)}\right)}$$

すると，交差エントロピー誤差（平均）は次で定義される．

$$\text{loss} = -\frac{1}{N} \sum_{n=1}^N \log\left(p_{y_n}^{(n)}\right)$$

評価手法

交差エントロピー誤差

なお，実装では softmax を明示せず，ロジット $z^{(n)}$ と正解 y_n から直接この量と等価な値を計算するクロスエントロピー関数を用いた．

Macro-F1

テスト集合全体の混同行列に基づき，各クラス $k \in \mathcal{Y}$ について次を定義する．

- TP_k : 真のラベルが k で，予測も k である件数
 - FP_k : 真のラベルが k 以外だが，予測が k である件数
 - FN_k : 真のラベルが k だが，予測が k 以外である件数
- クラス k の Precision, Recall, F1 は次で定義される．

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k}$$

$$\text{Recall}_k = \frac{\text{TP}_k}{\text{TP}_k + \text{FN}_k}$$

$$\text{F1}_k = \frac{2 \text{ Precision}_k \text{ Recall}_k}{\text{Precision}_k + \text{Recall}_k} = \frac{2 \text{ TP}_k}{2 \text{ TP}_k + \text{FP}_k + \text{FN}_k}$$

ただし，分母が 0 になる場合は 0 とする．

Macro-F1 はクラス平均として次で定義する．

$$\text{Macro-F1} = \frac{1}{|\mathcal{Y}|} \sum_{k \in \mathcal{Y}} \text{F1}_k, \quad (|\mathcal{Y}| = 75)$$