

質疑と回答

? 評価手法の Top-1 accuracy と Top-1 accuracy の定義を教えてください

テスト集合 $\mathcal{D}_{\text{test}}$ は N 個のサンプルからなる列として次で定義される.

$$\mathcal{D}_{\text{test}} = \{(x_n, y_n)\}_{n=1}^N, \quad x_n \in \{0, 1, \dots, 255\}^T, \quad y_n \in \mathcal{Y}$$

- バッチサイズ (実装上のミニバッチ処理に用いる): B
- 系列長: $T = 512$
- クラス集合 (全 75 クラス): $\mathcal{Y} = \{0, 1, \dots, 74\}$
- 1 バイトの値の集合: $\{0, 1, \dots, 255\}$
- n 番目サンプルの入力 (長さ T のバイト列): x_n
- それに対する正解ラベル (真のラベル; クラス ID): y_n
- テストサンプル総数: N

また, モデル出力 (ロジット) を

$$z^{(n)} = (z_0^{(n)}, z_1^{(n)}, \dots, z_{74}^{(n)}) \in \mathbb{R}^{75}$$

とし, 予測ラベル (Top-1) は次で与える.

$$\hat{y}_n = \arg \max_{k \in \mathcal{Y}} z_k$$

Top-1 accuracy

指示関数 $1[\cdot]$ (真なら 1, 偽なら 0) を用いて次と定義する.

$$\text{acc-1} = \frac{1}{N} \sum_{n=1}^N 1[\hat{y}_n = y_n]$$

Top-3 accuracy

サンプル n のロジット $z^{(n)}$ について, 値の大きい順に上位 3 つのクラス集合を次と定義する.

$$\text{Top3}(z^{(n)}) \subset \mathcal{Y}$$

このとき次が成り立つ.

$$\text{acc-3} = \frac{1}{N} \sum_{n=1}^N 1[y_n \in \text{Top3}(z^{(n)})]$$

? `.py` や `.md` などのソースファイルはデータセットに含まれていますか?

.py は含まれておらず, .md は含まれています. 具体的には, データセット FFT-75 の scenario #2 にあるカテゴリ, Human-readable text files (人間可読テキスト系) が次の 9 種ファイル種別を含んでいます.

MD / RTF / TXT / TEX / JSON / HTML / XML / LOG / CSV

本研究では scenario #2 を含むシナリオである scenario #1 を用いました.

なお, ZIP のような圧縮形式の中身に .py などが含まれている可能性はあります.

? 各評価手法の 交差エントロピー誤差 と Macro-F1 の定義を教えてください

交差エントロピー誤差

まず softmax 確率を次と定義する.

$$p_k^{(n)} = \frac{\exp(z_k^{(n)})}{\sum_{j \in \mathcal{Y}} \exp(z_j^{(n)})}$$

すると, 交差エントロピー誤差 (平均) は次で定義される.

$$\text{loss} = -\frac{1}{N} \sum_{n=1}^N \log(p_{y_n}^{(n)})$$

なお, 実装では softmax を明示せず, ロジット $z^{(n)}$ と正解 y_n から直接この量と等価な値を計算するクロスエントロピー関数を用いた.

Macro-F1

テスト集合全体の混同行列に基づき, 各クラス $k \in \mathcal{Y}$ について次を定義する.

- TP_k : 真のラベルが k で, 予測も k である件数
- FP_k : 真のラベルが k 以外だが, 予測が k である件数
- FN_k : 真のラベルが k だが, 予測が k 以外である件数

クラス k の Precision, Recall, F1 は次で定義される.

$$\text{Precision}_k = \frac{\text{TP}_k}{\text{TP}_k + \text{FP}_k}$$

$$\text{Recall}_k = \frac{\text{TP}_k}{\text{TP}_k + \text{FN}_k}$$

$$\text{F1}_k = \frac{2 \text{Precision}_k \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} = \frac{2 \text{TP}_k}{2 \text{TP}_k + \text{FP}_k + \text{FN}_k}$$

ただし, 分母が 0 になる場合は 0 とする.

Macro-F1 はクラス平均として次で定義する.

$$\text{Macro-F1} = \frac{1}{|\mathcal{Y}|} \sum_{k \in \mathcal{Y}} \text{F1}_k, \quad (|\mathcal{Y}| = 75)$$

? 結果に対して驚いたものがあれば教えてください.

圧縮ファイルの誤分類が見られることはその特性上想定していたが, JPEG を含む PDF のようなコンテナファイルの精度が上がらないことは想定しておらず驚いた.